

SK네트웍스 Family AI과정 23기

데이터 수집 및 저장 수집 데이터 보고서

산출물 단계	데이터 수집 및 저장
평가 산출물	수집 데이터 보고서
제출 일자	2026.04.10
깃허브 경로	https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN23-FINAL-3Team
작성 팀원	송민채

1. 수집 데이터 개요

데이터명	수집 대상	수집 목적	사용 예정 기능	출처/저작권
견종별 기본 특성	전 세계 견종 약 357종	견종 성격 기반 AI 일기 생성	일기 생성 프롬프트 구성, 캐릭터화	<u>The Dog API</u>
견종 대표 이미지	전 세계 견종 약 120종 (2만장 이상 이미지)	그림 일기 생성 시 외형 레퍼런스 제공	그림 일기 프롬프트	<u>Dog CEO Dog API</u>
한국관광공사 반려동물 동반 여행 API	전국 반려동물 동반 여행지	여행지 추천 및 실시간 검색 보완	반려견 동반 여행지 추천, 실시간 장소 검색	<u>공공데이터포털</u>

2. 수집 방법 및 자동화 절차

2-1. 견종별 기본 특성

- 수집 방식
 - API 호출 (The Dog API REST 엔드포인트)
- 수집 도구 및 스크립트
 - 사용 언어/라이브러리: Python + httpx + openai + chromadb + sentence-transformers
 - 자동화 여부: 최초 1회 수집 후 DB 저장 (정적 운영)
 - 오류 처리: API 응답 없을 시, 기본값은 강아지의 기본적인 특성으로 알려진 “활발하고 친근한 성격”으로 대체 저장
- 수집 흐름

The Dog API 호출 → 영문 temperament 수집 → gpt-4.1-mini 한국어 번역
→ gpt-4.1-mini 풍부한 성격 묘사 문장 생성 → ChromaDB 저장
- 예시 스크립트

GET <https://api.thedogapi.com/v1/breeds> → temperament (성격) 필드 추출
→ GPT 번역 → ChromaDB 저장

2-2. 견종 대표 이미지

- 수집 방식
 - API 호출 (Dog CEO Dog API 실시간 조회)
- 수집 도구 및 스크립트
 - 사용 언어/라이브러리: Python + httpx
 - 자동화 여부: 실시간 조회 (이미지 파일 저장 없음)
 - 오류 처리: API 응답 없을 시 기본 이미지 URL 대체
- 수집 흐름

Dog CEO API 호출 → 이미지 URL 실시간 반환
- 예시 스크립트

GET <https://dog.ceo/api/breed/{breed}/images/random> → 실시간 URL 반환

2-3 한국관광공사 반려동물 동반 여행 API

- 수집 방식
 - API 호출 (OpenAPI 실시간 연동)
- 수집 도구 및 스크립트
 - 사용 언어/라이브러리: Python + httpx
 - 자동화 여부: 실시간 조회 (동적 운영)
 - 오류 처리: API 타임아웃 시 DB 캐시 데이터로 대체
- 수집 흐름

한국관광공사 OpenAPI 호출 → 실시간 장소 검색 → 지도 마커 렌더링

3. 데이터 설명 및 구성

3-1. 견종별 기본 특성

필드명	데이터 타입	설명	예시
breed_name	TEXT	영문 견종명 (소문자)	affenpinscher
breed_name_ko	TEXT	한국어 견종명	아펜핀셔
temperament	TEXT	한국어 성격 키워드	자신감, 경계심, 장난기 많은
activity_level	TEXT	활동 특성	medium
document	TEXT	풍부한 성격 묘사 문장	아펜핀셔는 자신감 있고...

3-2. 반려견 동반 장소 정보 (통합)

필드명	데이터 타입	설명	예시
name	TEXT	장소명	멍멍 애견카페
address	TEXT	도로명 주소	서울 강남구 역삼동 123
lat	REAL	위도	37.4979
lng	REAL	경도	127.0276
category	TEXT	시설 유형	카페
conditions	TEXT	이용 조건	목줄 착용 필수
open_hours	TEXT	운영 시간	10:00 - 22:00

city	TEXT	시도명	서울
indoor	TEXT	실내 가능 여부	Y
outdoor	TEXT	실외 가능 여부	N
size_limit	TEXT	입장 가능 크기	소형/중형
extra_fee	TEXT	애견 동반 추가요금	없음
source	TEXT	데이터 출처	공공데이터포털

3-3. 데이터 양 및 저장 현황

데이터명	수집 대상	저장 포맷	운영 방식
건종별 기본 특성	전 세계 약 357종	ChromaDB	정적
건종 대표 이미지	전 세계 약 120종	실시간 조회	동적
한국관광공사 여행 API	약 21,130건 (한국관광공사 2025-03-24 데이터)	실시간 조회	동적

3-4. 저장 위치 및 포맷

- 저장 경로: data/chroma_db/
- 저장 포맷:
 - 개발/테스트: ChromaDB (chroma_db/)
 - 운영 환경: ChromaDB (VectorDB) + AWS RDS (MySQL)
- 인코딩: UTF-8

4. 법적·윤리적 검토

- 개인정보 포함 여부: 포함
 - 포함된 필드:
 - 이메일 (소셜 로그인 계정 식별용)
 - 닉네임 (프로필 표시용)
 - 프로필 사진 URL (사용자 동의 시 선택 수집)

- 소셜 고유 ID (카카오/구글/네이버 로그인 식별용)
- 나이 또는 출생연도 (서비스 개인화 및 통계 분석 목적)
- 성별 (서비스 개인화 및 통계 분석 목적)

● 비식별화 조치 여부: 고유키 대체

- 소셜 고유 ID는 내부 랜덤 고유 ID로 대체 저장 (보안 강화 목적)
- 이메일은 계정 식별 목적으로만 사용, 외부 노출 없음
- 서비스 탈퇴 시 수집된 개인정보 즉시 삭제

● 출처 및 사용권

데이터	공개 여부	라이선스/약관
소셜 로그인 개인정보	내부사용 한정	카카오/구글/네이버 OAuth 2.0 약관 준수
The Dog API	공개	공개 API, 상업적 이용 시 출처 표기 조건
Dog CEO Dog API	공개	별도 약관 없음, 공개 무료 API (Stanford Dogs Dataset 기반)
공공데이터포털 CSV	공개	이용허락범위 제한 없음
한국관광공사 API	공개	이용허락범위 제한 없음, API 키 발급 필요

라이선스 및 약관 검토 여부: 검토 완료
검토자 및 검토 일자: 송민채 / 2026.04.08

5. 데이터 품질 및 정합성 관리 방안

● 중복 제거 기준

- 견종 데이터: breed_id 기준 중복 제거
- 장소 데이터: 장소명 + 주소 기준 중복 제거 (3개 출처 통합 시 적용)

● 정합성 검증 방법

- 위경도 값 범위 검증 (한국 영토의 위경도 범위: 위도 33~38.7, 경도 124~132 외 제외): 해외 좌표로 잘못 입력되거나 0으로 입력되는 경우를 방지 하기 위해서.
- 필수 필드(장소명, 주소, 위경도) 누락 시 해당 레코드 제외
- temperament (성격) 필드 빈값일 경우 기본값 대체 ("활발하고 친근한 성격")

● Null 처리 및 결측치 전략

- 운영 시간: 정보 없을 경우 NULL 저장 후 프론트에서 '운영 시간 미제공 · 방문 전 문의 권장' 표시
- 이미지 URL: API 오류 시 기본 이미지 URL로 대체

● 표준화 전략

○ 텍스트 전처리 적용:

- 건종명 영문 소문자 통일
- 주소 도로명 기준 통일 (앞뒤 공백, 개행문자(\n) 제거)
- 시설 유형 8가지로 분류 표준화
(카페 / 놀이터 / 공원 / 숙박 / 음식점 / 관광지 / 쇼핑 / 기타)
- 위경도 소수점 4자리 통일

6. 변경 이력 및 보완 내역

변경일	변경자	변경 내용	비고
2026-04-08	송민채	데이터 수집 항목 초안 작성	초안
2026-04-10	송민채	데이터 수집 항목 최종 정리	
2026-04-29	정유선	미사용 데이터 삭제	