

인공지능 데이터 전처리 결과서

항목	내용
산출물 단계	데이터 전처리
평가 산출물	인공지능 데이터 전처리 결과서
제출 일자	2026-04-17
깃허브 경로	https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN23-FINAL-3Team
작성 팀원	정유선

1. 문서 개요

▶ 프로젝트명: withDOG

반려견을 위한 AI 기반 통합 서비스 플랫폼으로, 사용자의 자연어 질의를 인텐트에 따라 다이어리 작성 / 장소추천 / 시설정보 세 가지 기능으로 라우팅합니다.

▶ 전처리 목적

사용자 발화 텍스트를 KoELECTRA 기반 인텐트 분류 모델 학습에 적합한 형태로 정제하고, 균형 잡힌 고품질 한국어 텍스트 데이터셋을 구축합니다.

▶ 문제 정의

withDOG 사용자의 자유 형식 자연어 질의를 아래 세 카테고리로 분류하는 모델을 학습하기 위한 데이터셋을 구축합니다.

- 다이어리 작성: 반려견 일상 기록 및 일기 작성 요청
- 장소추천: 반려견 동반 가능 장소(카페, 공원, 숙소 등) 추천 요청
- 시설정보: 동물병원, 미용실, 훈련소 등 반려견 관련 시설 정보 요청

2. 데이터셋 개요

▶ 데이터 출처 및 수집 방법

팀원이 직접 작성한 자체 제작 데이터셋입니다. 각 카테고리별 다양한 표현 방식과 구어체를 반영하여 수작업으로 수집하였으며, 카테고리별 110건씩 균형 있게 구성했습니다.

▶ 데이터 컬럼 구성

항목명	설명	예시
text	사용자 발화 텍스트 (한국어 자연어)	"우리 강아지 오늘 일기 써줘"
label	인텐트 카테고리 레이블	다이어리 작성 / 장소추천 / 시설정보

▶ 카테고리별 데이터 분포

카테고리	건수	비율
다이어리 작성	110건	33.3%
장소추천	110건	33.3%
시설정보	110건	33.3%
합 계	330건	100%

▶ 원본 데이터 샘플

카테고리	발화 예시 (text)	레이블 (label)
다이어리 작성	"우리 강아지 오늘 일기 써줘"	다이어리 작성
다이어리 작성	"멍멍이가 오늘 공원에서 뛰어 놀았어"	다이어리 작성
장소추천	"강아지 데리고 갈 수 있는 카페 알려줘"	장소추천
장소추천	"반려견 동반 가능한 산책로 추천해줘"	장소추천
시설정보	"근처 동물병원 찾아줘"	시설정보
시설정보	"강아지 미용실 어디 있어?"	시설정보

3. 전처리 프로세스 개요

▶ 전체 흐름

① 원본 데이터 로드 → ② 결측치·중복 제거 → ③ 텍스트 정제 → ④ 레이블 인코딩 → ⑤ 학습/검증 분리 → ⑥ 모델 입력 형식 변환

▶ 전처리 파이프라인 요약

단계	목적	수행 작업	사용 도구
텍스트 정제	불필요 문자 제거	특수문자, 이모지, URL 제거	Python re

공백 정규화	중복 공백 처리	연속 공백 단일 공백으로 치환	Python str
결측치 처리	누락 데이터 제거	text/label 누락 행 제거	pandas
중복 제거	중복 샘플 제거	text 기준 중복 행 제거	pandas
레이블 인코딩	텍스트→숫자 레이블	카테고리 문자열을 정수 ID로 변환	sklearn
데이터 분리	학습/검증 분할	train 80% / val 20% (stratified)	train_test_split

4. 세부 전처리 단계

4.1 결측치 처리

결측치 존재 여부: 없음 (데이터 수집 단계에서 모든 샘플을 직접 작성하여 결측치 미발생)

컬럼명	결측률	처리 방법
text	0%	해당 없음 (수집 시 검증 완료)
label	0%	해당 없음 (카테고리별 균형 수집)

확인 코드:

```
import pandas as pd
df = pd.read_csv("intent_data.csv")
print(df.isnull().sum()) # 모든 컬럼 결측값 0 확인
```

4.2 이상치 처리

항목	기준	처리 방식	제거 수
text 길이	5자 미만 발화	해당 행 제거	0건
중복 발화	동일 text 중복	중복 제거 후 첫 행 유지	0건

수집 시 품질 관리로 이상치가 없어 실제 제거된 데이터는 없습니다.

4.3 텍스트 정규화

KoELECTRA 토크나이저는 한국어 원문을 직접 처리하므로 최소한의 정제만 수행했습니다.

- 양측 공백 제거: `str.strip()`
- 연속 공백 정리: `re.sub(r"Ws+", " ", text)`
- 특수문자 제거: 이모지·특수기호 제거

```
import re
def clean_text(text):
    text = text.strip()
```

```

text = re.sub(r"Ws+", " ", text)
text = re.sub(r"^[^WwWs가-힣]", "", text)

return text

df["text"] = df["text"].apply(clean_text)

```

4.4 레이블 인코딩

레이블 문자열	정수 ID	샘플 수
다이어리 작성	0	110
장소추천	1	110
시설정보	2	110

```
label_map = {"다이어리 작성": 0, "장소추천": 1, "시설정보": 2}
```

```
df["label_id"] = df["label"].map(label_map)
```

5. 학습/검증 데이터 분리

- 기준: Stratified 무작위 분할 (카테고리 비율 유지)
- 비율: Train 80% (264건) / Val 20% (66건) | random_state=42

```

from sklearn.model_selection import train_test_split
train_df, val_df = train_test_split(
    df, test_size=0.2, random_state=42, stratify=df["label"]
)

# 학습 데이터: 264건 | 검증 데이터: 66건

```

구분	데이터 수	비율
학습 데이터	264건	80%
검증 데이터	66건	20%
전체	330건	100%

6. 전처리 결과 요약 및 평가

▶ 전처리 전후 비교

항목	전처리 전	전처리 후
----	-------	-------

전체 건수	330건	330건
결측치	0건	0건 (변경 없음)
중복 샘플	0건	0건 (변경 없음)
카테고리 균형	110:110:110	110:110:110 (균형 유지)
학습/검증 분리	-	264건 / 66건

▶ 모델 학습을 통한 전처리 품질 검증

전처리된 데이터로 KoELECTRA 모델(monologg/koelectra-base-v3-discriminator)을 5 에포크 학습한 결과, 검증 정확도 98.48%를 달성하여 데이터 전처리 품질이 우수함을 확인했습니다.

에포크별 학습 결과 (검증 데이터 기준)

Epoch	Loss	Accuracy	비고
1	1.0414	0.8030 (80.30%)	
2	0.7467	0.9242 (92.42%)	
3	0.4634	0.9848 (98.48%)	★ 최고 성능 저장
4	0.3037	0.9848 (98.48%)	
5	0.2406	0.9848 (98.48%)	

최종 평가 리포트 (검증 데이터 66건)

클래스	Precision	Recall	F1-score	Support
다이어리 작성	1.0000	1.0000	1.0000	22
장소추천	0.9565	1.0000	0.9778	22
시설정보	1.0000	0.9545	0.9767	22
accuracy	-	-	0.9848	66
macro avg	0.9855	0.9848	0.9848	66
weighted avg	0.9855	0.9848	0.9848	66

▶ 품질 지표 요약

- 전체 정확도: 98.48% (65/66건 정답)
- 다이어리 작성: Precision 1.000 / Recall 1.000 / F1 1.000 — 완벽 분류
- 장소추천: Precision 0.9565 / Recall 1.000 / F1 0.9778
- 시설정보: Precision 1.000 / Recall 0.9545 / F1 0.9767
- Macro F1: 0.9848 — 세 카테고리 모두 고른 성능

▶ 향후 활용 방안

구축된 데이터셋 및 학습된 KoELECTRA 인텐트 분류 모델은 withDOG 서비스의 챗봇 라우팅 시스템에 적용됩니다. 사용자 질의가 입력되면 인텐트를 자동 분류하고, 다이어리 작성 체인 / 장소추천 RAG / 시설정보 조회 로직으로 분기합니다. 향후 서비스 데이터 증가 시 추가 Fine-tuning으로 성능을 지속 향상시킬 계획입니다.

※. 변경 이력

변경일	변경자	변경 내용	비고
2026-04-17	정유선	최초 작성: 인텐트 분류 데이터 전처리 결과서	초안