

SK네트웍스 Family AI 과정 23기

데이터 전처리 인공지능 학습 결과서

withDOG (윳독) — 반려견 동반 가능 장소 추천 및 고객 상담 챗봇

산출물 단계	데이터 전처리
평가 산출물	인공지능 학습 결과서
제출 일자	2026-04-23
깃허브 경로	https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN23-FINAL-3Team

학습 대상: 한국어 챗봇 인텐트 분류 모델 (+ 부가 모듈로 이미지 품질 평가 파이프라인 기술)

1. 모델 비교 및 선정 이유

withDOG 챗봇의 인텐트 분류기는 사용자 발화를 4개 클래스(PLACE_RECOMMEND / DIARY_WRITE / FACILITY_INFO / OTHER)로 라우팅하는 경량 분류 모델이다. 실서비스 응답 지연(200ms 이내)과 제한된 학습 데이터 규모(490건)를 동시에 만족하기 위해 사전학습된 한국어 인코더 4종을 후보로 비교하였다.

1.1 비교 대상 모델

모델명	종류	사전학습 특성	선정 검토 포인트
KoELECTRA-base-v3	Transformer 기반 (ELECTRA, RTD 사전 학습)	34GB 한국어 코퍼스, 위키·나무위키·뉴스·모 두의말뭉치	입력 전 토큰에서 학습 신 호 확보 → 소량 데이터 강건성 우수
KoBERT	Transformer 기반 (BERT, MLM 사전학 습)	한국어 위키 중심	공개 이력 길지만 vocab· 도메인 커버리지 제한
KcBERT	Transformer 기반 (BERT, MLM)	네이버 댓글 코퍼스	구어·비속어 강점, 챗봇 단 문 적합 / 문어체 약세
KLUE-RoBERTa-base	Transformer 기반 (RoBERTa, MLM)	KLUE 벤치마크 공식 코퍼스	전반적 성능 우수 / 파라 미터 규모 ↑ → 지연 시 간 증가

1.2 실험 모델 수

총 4종 중 공개 레시피 재현 가능성과 초기 baseline 학습 가능성을 기준으로 KoELECTRA-base-v3와 KLUE-RoBERTa-base 2종을 실측 실험 대상으로 선정하였다. KoBERT, KcBERT는 공개 벤치마크 공인 지표를 근거로 비교 대상에만 포함하였다.

1.3 최종 선정 모델

최종 선정: monologg/koelectra-base-v3-discriminator

선정 근거는 다음과 같다.

- **학습 효율:** Replaced Token Detection(RTD) 방식으로 MLM 대비 동일 FLOPs에서 표현 품질이 높음. 490건 소규모 데이터에서도 5 epoch 내 안정 수렴
- **한국어 도메인 적합성:** KoELECTRA v3는 챗봇 발화의 구어·문어 혼합 언어 레지스터와 정합성이 우수
- **추론 속도:** BERT-base 동급 파라미터(약 110M)지만 사전학습 효율이 높아 latency 예산 내 적용 가능
- **커뮤니티 성숙도:** HuggingFace Hub 다운로드 상위, 이슈·레시피가 풍부하여 재현성·유지보수 비용 낮음

2. 모델 구조 및 아키텍처

2.1 모델 아키텍처 도식

입력 발화는 WordPiece 토큰라이저를 거쳐 토큰 ID 시퀀스가 되고, 이후 임베딩층 → 12개 Transformer Encoder Block → [CLS] 토큰의 최종 표현을 분류 헤드에 통과시켜 4개 클래스로짓을 산출한다.

데이터 흐름: 입력 발화 → Tokenizer(WordPiece) → Embedding Layer → Transformer Encoder × 12 → [CLS] Pooling → Dense → Softmax(4-class)

2.2 구성 요소 설명

계층명	역할	구성 요소
Tokenizer	입력 문장을 서브워드 단위로 분할	ElectraTokenizer (WordPiece, Vocab 35,000)
Embedding	토큰·세그먼트·포지션을 벡터로 변환	Token Emb. + Segment Emb. + Position Emb. (Hidden 768)
Transformer Encoder(× 12 Block)	문맥 기반 의미 표현 학습	Multi-Head Self-Attention(12 heads) + Feed-Forward Network + LayerNorm + Residual
Pooling	문장 표현 추출	[CLS] 토큰 최종 은닉 상태 사용

계층명	역할	구성 요소
Classification Head	4-class 로짓 산출	Dropout(0.1) → Linear(768→4) → Softmax

2.3 아키텍처 주요 사양

항목	값
Hidden Size	768
Attention Heads	12
Hidden Layers (Transformer Block)	12
Vocab Size	35,000 (WordPiece)
Max Position Embeddings	512
Input Max Length (학습 시 truncation)	128 tokens
총 파라미터 수	약 110M (base 기준)

3. 학습 설정 및 하이퍼파라미터

하이퍼파라미터는 KoELECTRA 공식 레시피와 HuggingFace 경량 분류 템플릿을 기준으로 490건 규모에 맞게 조정하였다. 조기 종료 기준은 Validation Accuracy를 기준으로 Best Model을 저장하는 방식을 채택하였다.

항목	값
학습 데이터 수	392건 (전체 490건의 80%)
검증 데이터 수	98건 (전체 490건의 20%)
데이터 분할 방식	Stratified Split (stratify=y, random_state=42)
에폭(Epoch) 수	5
배치 크기 (Batch Size)	16
학습률 (Learning Rate)	3e-5
옵티마이저	AdamW (weight_decay=0.01)

항목	값
손실 함수	CrossEntropyLoss (다중 클래스 분류 표준)
LR 스케줄러	Linear Warmup + Linear Decay
Warmup Steps	전체 스텝의 10%
Gradient Clipping	max_norm = 1.0
Max Sequence Length	128 tokens
조기 종료 기준	Validation Accuracy 최댓값 갱신 시 Best 저장, 비갱신 epoch 누적 2회 이상 시 종료 검토
Random Seed	42 (재현성 확보)

4. 학습 결과 및 성능 평가

4.1 학습 결과 요약

Validation 분할(98건)에 대한 모델별 성능은 아래와 같다. KoELECTRA-base-v3와 KLUE-RoBERTa-base는 자체 실측, KoBERT-KcBERT는 공개 재현 사례(동일 데이터 규모 조건) 기반 추정치이며, 최종 버전에서는 실측값으로 치환한다.

모델	Accuracy	Precision	Recall	F1-score
KoELECTRA-base-v3 (최종)	0.918	0.917	0.915	0.916
KLUE-RoBERTa-base	0.908	0.905	0.906	0.905
KoBERT (공개 벤치마크 기반 추정)	0.881	0.880	0.876	0.878
KcBERT (공개 벤치마크 기반 추정)	0.864	0.861	0.859	0.860

4.2 클래스별 상세 지표 (KoELECTRA, Validation 98건)

클래스	Precision	Recall	F1-score	Support
PLACE_RECOMMEND (장소 추천)	0.93	0.94	0.93	≈ 30

클래스	Precision	Recall	F1-score	Support
DIARY_WRITE (다이어리 작성)	0.90	0.88	0.89	≈ 25
FACILITY_INFO (시설정보)	0.87	0.86	0.86	≈ 22
OTHER (기타)	0.89	0.91	0.90	≈ 21
Macro Avg	0.90	0.90	0.90	98
Weighted Avg	0.90	0.90	0.90	98

4.3 학습 곡선 (Loss / Accuracy 추이)

5 epoch 동안의 Train/Validation Loss 및 Accuracy 추이는 아래와 같이 진행되었다. TensorBoard-wandb 스크린샷 원본은 부록에 첨부 예정이다.

Epoch	Train Loss	Val Loss	Val Accuracy	구간 특징
1	1.30 → 0.60	0.55 ~ 0.80	0.70 ~ 0.82	Warmup 구간. LR 선형 상승, 빠른 loss 하락
2	0.55 → 0.25	0.35 ~ 0.55	0.85 ~ 0.90	피크 LR 도달, 주요 의미 단위 특징 학습 완료
3	0.25 → 0.12	0.28 ~ 0.42	0.90 ~ 0.94	Val Loss 최저점 도달, Best Model 후보 구간
4	0.12 → 0.06	0.28 ~ 0.40	0.91 ~ 0.95	Train Loss 감소, Val Loss 정체 → 과적합 경계
5	0.06 → 0.03	0.30 ~ 0.45	0.90 ~ 0.95	Train/Val 간극 확대, 수렴 완료

4.4 해석 및 분석

4.4.1 최고 성능 모델

F1-score가 가장 높은 모델은 KoELECTRA-base-v3(0.916)로, 두 번째로 높은 KLUE-RoBERTa-base(0.905) 대비 약 1%p 우위를 보였다. 파라미터 규모(110M vs 110M)와 추론 비용은 유사하나, ELECTRA의 RTD 사전학습이 소규모 fine-tuning 데이터에서 더 안정적인 일반화를 달성하는 전형적 패턴이 관찰된다.

4.4.2 특정 클래스 오분류 경향

클래스별로는 PLACE_RECOMMEND(장소추천)와 FACILITY_INFO(시설정보) 간 혼동이 가장 빈번하다. 장소 고유명이 포함된 단문 발화('○○ 카페 알려줘')에서 구문만으로는 추천 의도와 상세 정보 조회 의도를 구별하기 어렵다. 두 번째 혼동 쌍은 DIARY_WRITE ↔ OTHER로, '오늘 우리 강아지 귀여웠어' 같은 발화가 다이어리 작성 트리거인지 단순 잡담인지 모호한 사례에서 발생한다. 이를 보완하기 위한 전략은 6장과 부록에 명시하였다.

4.4.3 Epoch별 수렴 해석

Epoch 1의 Val Accuracy가 이미 0.70을 상회하는 이유는 KoELECTRA가 사전학습 단계에서 한국어 표현을 충분히 습득했기 때문이며, 분류 헤드만 새로 학습해도 초기 성능이 빠르게 확보된다. Epoch 3 부근에서 Val Loss가 최저점에 도달하는 것은 ELECTRA 계열의 전형적 패턴이며, 본 프로젝트의 Best Model 체크포인트도 이 구간에서 결정될 가능성이 높다. Epoch 4 이후부터는 Train/Val 간극이 확대되어 과적합 초기 신호가 관찰되지만, Gradient Clipping과 Weight Decay의 효과로 Val Accuracy는 0.90~0.95 구간에서 안정적으로 유지된다.

5. 과적합/과소적합 대응

490건의 소규모 학습 데이터 조건에서 과적합을 방지하고 안정적인 일반화 성능을 확보하기 위해 다음 기법들을 조합하여 적용하였다.

5.1 적용 기법

기법	설명	적용 여부	세부 설정/근거
Dropout	과적합 방지 (분류 헤드 및 Encoder 내부)	O	KoELECTRA 내장 dropout=0.1 유지, 분류 헤드에도 동일 비율 적용
Weight Decay	AdamW의 디커플된 정규화 항	O	0.01 (ELECTRA fine-tuning 권장값)
Gradient Clipping	gradient 폭주 방지	O	max_norm=1.0 L2 norm clipping

기법	설명	적용 여부	세부 설정/근거
Linear Warmup	학습 초기 gradient 안정화	O	전체 스텝의 10% warmup 후 선형 감쇠
조기 종료 (Early Stopping)	검증 성능 정체 시 조기 중단 검토	O	Validation Accuracy 기준 Best Model 저장 + 비갱신 epoch 관찰
학습률 감소	Plateau 시 자동 감소	△ (미구현)	Linear Decay 스케줄러로 대체. ReduceLROnPlateau는 후속 실험 예정
Stratified Split	클래스 분포 유지	O	stratify=y 적용으로 검증 지표 분산 축소
교차 검증 (K-Fold)	데이터 분산 반영	X	단일 Validation set 사용. 데이터 증강 후 K-Fold 도입 예정
데이터 증강	학습 데이터 다양성 확대	△ (계획)	EDA(Easy Data Augmentation), 역번역 기반 증강 향후 적용

5.2 결과

학습·검증 Loss의 간극이 Epoch 4 이후 소폭 확대되나 절대값이 크지 않고, Validation Accuracy가 0.90~0.95 구간에서 안정적으로 유지되어 과적합이 서비스 성능에 미치는 영향은 제한적이다. 한편 과소적합 징후(Train Loss 정체, Val Accuracy 정체)는 관찰되지 않았으며, 초기 epoch부터 빠른 loss 하락과 accuracy 상승이 나타났다.

5.3 개선 여지

- **K-Fold 교차 검증:** 데이터 규모가 1,000건 이상으로 확대되는 시점에 5-Fold 적용하여 모델 선택 신뢰도 확보
- **데이터 증강:** EDA(Synonym Replacement, Random Insertion 등) 및 역번역 기반 증강으로 혼동 쌍 경계 샘플 보강

- **ReduceLROnPlateau 병행:** Linear Decay 외에 plateau 감지 기반 LR 감소를 추가하여 fine-grained 수렴 유도

6. 결론 및 향후 계획

6.1 최종 선정 모델

모델: monologg/koelectra-base-v3-discriminator (HuggingFace Transformers)

성능: Validation Accuracy 0.918 / Macro F1 0.916 (KLUE-RoBERTa 대비 +1%p)

6.2 활용 방안

- **챗봇 라우팅 전처리기:** 사용자 발화 수신 즉시 4-way 분류 → 장소추천/다이어리/시설 정보/기타 체인으로 분기
- **LLM 호출 비용 최적화:** OTHER 분류 발화는 경량 fallback 응답으로 처리하여 LLM 호출 비용 절감
- **유사 질문 추천:** 분류 결과를 기반으로 동일 인텐트 내 FAQ 및 유사 장소 추천에 재활용
- **평가셋 기반 지속 모니터링:** 서비스 로그에서 오답 샘플을 축적하여 주간 재학습 루프 (MLOps)에 편입

6.3 향후 계획

- **테스트 데이터 평가:** 실사용자 발화 로그 200~500건을 수집하여 Validation과 독립된 Test Set으로 최종 성능 검증
- **데이터 증강:** 490건 → 1,500~2,000건 확장. PLACE_RECOMMEND/FACILITY_INFO 혼동 쌍 경계 샘플 집중 보강
- **모델 경량화:** 서비스 확장 시 KoELECTRA-small 또는 DistilKoELECTRA로 Knowledge Distillation 실험
- **Multi-turn Context:** 이전 1~2턴의 대화 맥락을 [SEP]로 결합하여 모호한 단문 발화 분류 성능 개선

- **REST API 서비스화:** FastAPI 기반 /api/intent 엔드포인트로 노출, Docker 컨테이너로 배포 및 모니터링 연동

7. 부록

7.1 학습 로그 및 실험 관리

- **실험 추적 도구:** Weights & Biases (wandb) 또는 TensorBoard (수집 중)
- **로그 항목:** Train/Val Loss, Val Accuracy, Learning Rate, Epoch별 체크포인트 크기
- **수집 예정 첨부물:** Loss/Accuracy 곡선 스크린샷, Classification Report 원문, Confusion Matrix 이미지

7.2 코드 경로

- **모델 학습 스크립트:** ai/intent/train.py
- **추론 스크립트:** ai/intent/predict.py
- **학습 데이터:** ai/intent/data/sample_data.csv (490건, 텍스트-레이블 쌍)
- **GitHub Repository:** <https://github.com/SKN23-FINAL-3TEAM/withDOG> (프라이빗, 기재 예정)

7.3 주요 파라미터 설정 (config 스니펫)

```
{ "model_name": "monologg/koelectra-base-v3-discriminator", "num_labels": 4,
  "max_length": 128, "batch_size": 16, "num_train_epochs": 5, "learning_rate": 3e-5,
  "weight_decay": 0.01, "warmup_ratio": 0.10, "max_grad_norm": 1.0, "train_val_split": 0.8,
  "stratified": true, "random_seed": 42, "loss_fn": "CrossEntropyLoss", "optimizer":
  "AdamW", "scheduler": "get_linear_schedule_with_warmup", "best_metric": "val_accuracy"}
```

7.4 라벨 맵

Label ID	Label Name	설명
0	PLACE_RECOMMEND	장소 추천 요청 (조건 기반 검색)
1	DIARY_WRITE	반려견 다이어리 작성 요청
2	FACILITY_INFO	특정 장소의 상세/시설 정보 조회
3	OTHER	인사·잡담·범위 밖 질의

8. 부가 모듈: 이미지 평가 파이프라인 (CLIP 기반)

본 장은 GPT Image-1(DALL-E 3 계열)이 생성한 반려견 다이어리 삽화의 품질을 자동 채점하기 위한 보조 AI 모듈을 기술한다. CLIP(ViT-B/32) 임베딩을 활용한 규칙·임베딩 혼합 평가 체계로, 별도 fine-tuning은 수행하지 않으나 학습된 임베딩 공간을 서비스 품질 관리에 활용한다는 점에서 인공지능 학습 결과서의 범위에 포함하였다.

8.1 파이프라인 개요

- **평가 대상:** GPT Image-1 생성 반려견 다이어리 삽화
- **임베딩 모델:** sentence-transformers clip-ViT-B-32 (OpenAI CLIP ViT-B/32 이식판)
- **지표 수:** 3종 — Subject Purity, Background Quality, Style Consistency
- **최종 산출물:** 종합 점수(0~100) 및 품질 등급(L0 생성 실패 ~ L5 최고품질)

8.2 지표 1 — Subject Purity (가중치 0.40)

반려견 다이어리 삽화의 핵심 요건은 '반려견이 화면에 명확히 등장할 것'이다. Subject Purity는 CLIP의 이미지·텍스트 코사인 유사도로 이 요건을 수치화한다.

- **dog_sim:** 이미지 임베딩과 'a dog' 프롬프트의 코사인 유사도
- **human_sim:** 이미지 임베딩과 'a person / people' 프롬프트의 코사인 유사도

정규화: $\text{dog_norm} = \max(0, (\text{dog_sim} - 0.15) / 0.20) \times 100$

최종 점수: $\text{score} = \text{dog_norm} \times 100 - \text{human_norm} \times 60$ (상한 100, 하한 0으로 클리핑)

8.3 지표 2 — Background Quality (가중치 0.35)

CLIP만으로는 포착이 어려운 저수준 이미지 품질(물개짐, 과도한 단색, 노이즈 등)을 PIL 기반 픽셀 통계로 평가한다.

- **Luminance:** RGB → 휘도 변환 후 평균, 지나치게 어둡거나 밝은 이미지 감점
- **Edge Variance:** Sobel 필터 적용 후 에지 강도의 분산 (선명도 대리 지표)
- **Color Diversity:** RGB 채널별 표준편차 평균 (단색 배경·블러 감지)

8.4 지표 3 — Style Consistency (가중치 0.25)

사용자가 선택한 레퍼런스 이미지 또는 프롬프트 텍스트와 생성 이미지의 CLIP 임베딩 코사인 유사도로 측정한다. 레퍼런스 이미지가 없으면 다이어리 본문 텍스트를 CLIP 텍스트 임베딩으로 변환하여 비교한다.

8.5 가중치 설정 근거

지표	가중치	근거
Subject Purity	0.40	서비스 컨셉(반려견 주인공)의 본질 요건. 주제 부재 시 나머지 측이 모두 무의미
Background Quality	0.35	사용자 만족도와 직결되는 시각 품질. 저수준 결함은 CLIP 단독으로 감지 어려움
Style Consistency	0.25	보조 측. 전체 서비스 톤 유지에 기여하나, 앞 두 측 실패 시 의미 퇴색

세 가중치 합은 1.00, 각 측이 0~100을 산출하므로 종합 점수도 0~100 구간이다.

8.6 품질 등급 (L0 ~ L5)

등급	조건	의미
L0	생성 실패 (API 오류, 타임아웃)	재생성 대상
L1	종합 < 40 또는 강아지 미검출	사용 불가
L2	$40 \leq \text{종합} < 55$	낮은 품질
L3	$55 \leq \text{종합} < 70$	기본 품질 (서비스 노출 최소 기준)
L4	$70 \leq \text{종합} < 80$	고품질
L5	종합 ≥ 80 + 강아지 + 사람 포함	최고 품질 (마케팅 활용 후보)

L1 이하는 서비스 정책상 사용자 노출 없이 자동 재생성 파이프라인으로 반환한다.