

SK네트웍스 Family AI 과정 23기

모델링 및 평가 수집된 데이터 및 전처리 문서

withDOG (윳독) — 반려견 동반 가능 장소 추천 및 고객 상담 챗봇

산출물 단계	모델링 및 평가
평가 산출물	수집된 데이터 및 전처리 문서
제출 일자	2026-04-23
깃허브 경로	https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN23-FINAL-3Team

데이터 파이프라인: RDB(장소 21,192건) · 벡터DB(블로그 리뷰 임베딩) · 인텐트 학습(490건)

1. 데이터 수집 개요

withDOG 서비스는 (1) 반려견 동반 가능 장소 RDB·벡터DB, (2) 사용자 발화 인텐트 분류 학습 데이터 두 축의 데이터셋을 운영한다. 본 장은 각 데이터셋의 수집 목적, 출처, 수집 방식, 법적·윤리적 고려 사항을 정리한다.

데이터 수집 기간: 2026-03-10 ~ 2026-04-20 (약 6주)

수집 방식: 공공데이터 Open API (JSON/XML) + 블로그 크롤링 (BeautifulSoup) + 자체 수기 라벨링

1.1 수집 목적

장소 데이터는 위치·시설 조건에 따른 반려견 동반 가능 장소 큐레이션과 RAG 기반 상세 정보 질의응답을 위한 지식베이스로 활용된다. 인텐트 학습 데이터는 사용자 발화를 장소추천 / 다이어리 작성 / 시설정보 / 기타 4개 클래스로 라우팅하여 LLM 호출 비용을 최적화하고 체인별 전문 프롬프트 품질을 보장하는 데 목적이 있다.

1.2 데이터 출처

장소 정보와 블로그 리뷰는 공공 API·공개 웹에서 수집하였으며, 인텐트 학습 데이터는 팀 내부에서 수기 라벨링하였다. 세부 출처는 다음과 같다.

데이터명	출처	수집 방식	형식
반려동물 동반 가능 여행지	한국관광공사 TourAPI 4.0 (pet_tour 서비스)	Open API 호출 (JSON)	JSON
장소 메타정보 보강	공공데이터포털·한국관광공사 지역 코드	REST API + 코드 매핑	JSON/CSV
블로그 리뷰 텍스트	네이버 블로그 검색 (장소명 +반려견 키워드)	웹 크롤링 (BeautifulSoup)	HTML → TXT
인텐트 학습 샘플	팀 내부 수기 라벨링 (PM·팀원 4인)	Google Sheets → CSV 변환	CSV

데이터명	출처	수집 방식	형식
품종 검증용 이미지	Ultralytics YOLOv8 사전학습 가중치	모델 다운로드 (추론 전용)	PT (가중치)

1.3 수집 대상 및 범위

- **대상(장소):** 전국 반려견 동반 가능 장소 (음식점·카페·공원·숙박·관광지·애견 전용 시설 등)
- **대상(리뷰):** 서울 MVP 범위 장소(11,831건)에 한정하여 블로그 리뷰를 수집·임베딩 (전국 리뷰 크롤링은 Phase 2 로드맵)
- **대상(인텐트):** withDOG 챗봇 예상 사용자 발화 시나리오 (장소 문의·다이어리 요청·시설 상세 조회·범위 외 질의)
- **총 수집 건수:** 장소 원천 70,651건 → 정제 후 21,192건 유효 레코드 · 인텐트 샘플 490건
- **개인정보 포함 여부:** 아니오 (공공 데이터·공개 블로그·자체 작성 문장만 사용)
- **민감 정보 여부 및 조치:** 없음 (블로그 리뷰는 작성자 닉네임·사진을 저장하지 않고 본문 텍스트만 추출)

1.4 법적·윤리적 고려 사항

- **개인정보보호법 준수 여부:** ○
- **데이터 수집 사전 동의 유무:** N/A — 공개된 비식별 데이터(공공 API, 공개 블로그)만 수집. 개인정보·식별자 미포함
- **자동 크롤링 시 robots.txt 확인 여부:** ○ — 네이버 검색 robots.txt 및 이용 약관을 준수하여 허용 경로·요청 간격(2초 이상)을 유지
- **수집 데이터의 활용 범위 명시 여부:** ○ — 프로젝트 범위 내 비상업적 교육·연구 용도로 한정. 서비스 상용화 시 각 출처별 라이선스 재검토 예정
- **라이선스 정리:** TourAPI는 공공누리 제1유형(출처표시) 준수, 블로그 리뷰는 인용·요약 범위 내 사용, YOLOv8 가중치는 AGPL-3.0 하에 추론 전용으로 활용

1.5 데이터 현황 요약 (볼륨·구성)

정제가 완료된 시점의 데이터셋 전체 구성은 다음과 같다. 장소 데이터는 전국 기준으로 RDB에 적재되어 있으며, 서울 MVP 스코프 장소에 대해 블로그 리뷰를 추가 수집하여 벡터 DB에 임베딩하였다.

데이터셋	건수	저장소	비고
장소 메타 (전국)	21,192건	MySQL (dog_places)	원천 70,651건 대비 30.0% 유효
장소 메타 (서울 MVP)	11,831건	MySQL (동일 테이블)	RAG 후보군 핵심 범위
블로그 리뷰 임베딩 (서울)	서울 장소당 평균 3~5건	ChromaDB (dog_places 컬렉션)	768차원 ko-sroberta-multitask
인텐트 학습 데이터	490건	CSV (sample_data.csv)	4개 클래스 균형 분포

장소 원천 대비 최종 유효 건수 비율이 30%로 나타나는데, 이는 중복 좌표·지역 코드 이상치·필수 필드 결측으로 인해 파이프라인 각 단계에서 필터링된 결과이며, 세부 내역은 3.4절 전처리 프로세스 플로우에 기술한다.

2. 데이터 저장 및 검증

2.0 저장 방식

- **장소 RDB 저장 경로:** MySQL 8.0 · 데이터베이스 withdog · 테이블 dog_places (컬럼 23개, InnoDB)
- **벡터 저장 경로:** ChromaDB persistent client · 컬렉션 dog_places · distance=cosine
- **인텐트 학습 데이터:** ai/intent/data/sample_data.csv (UTF-8, 헤더: text,label)
- **원본 아카이브:** S3 버킷 withdog-raw (버전 관리 활성화) — 재현성 확보를 위한 원천 JSON 스냅샷 보관
- **일관성 확보 방법:** 적재 전 Pydantic 스키마 검증, 좌표 필드 WGS84 소수점 7자리 고정, is_indoor-is_outdoor-has_parking 를 ENUM('Y','N')로 제약

장소 RDB 의 주요 컬럼 구성은 다음 표와 같으며, 총 23개 필드가 카테고리·위치·반려견 수

용 조건·편의 시설·설명·이미지의 6개 도메인으로 구분된다.

그룹	컬럼	설명
식별·분류	content_id, name, sub_category	TourAPI 고유 ID / 장소명 / 세부 카테고리(카페·공원 등)
위치	city, district, address, lat, lng	시·구 행정 구분, 전체 주소, WGS84 위·경도 (소수점 7자리)
공간 속성	is_indoor, is_outdoor, pet_zone_type	실내·실외 여부 ENUM(Y/N), 반려견 구역 유형(전용·공용 등)
수용 조건	pet_size_limit, pet_restrictions	크기 제한 문자열, 동반 제한 사항(목줄·입마개 등)
편의	has_parking, operation_info	주차 가능 여부 ENUM(Y/N), 운영 시간/휴무/전화 통합 문자열
설명	description	검색·임베딩용 자연어 요약 (후처리 단계에서 생성)
이미지	firstimage, firstimage2	대표 이미지 URL 1·2 (원본 출처 유지)

2.1 중복 및 정합성 검증

- **중복 제거 기준:** content_id 기준 UNIQUE 제약 + (name, address) 쌍 기준 유사도 검증으로 TourAPI 페이지네이션 중복·API 버전 차이로 인한 중복 제거
- **정합성 확보 방법:**
 - 좌표 범위 검증: 위도 33.0~38.8, 경도 124.5~131.9 범위 외 레코드 제거
 - 필수 필드 결측 제거: name·address·lat·lng 중 하나라도 NULL 인 행 삭제
 - 타입 제약: is_indoor·is_outdoor·has_parking 을 ENUM('Y','N') 로 제약, 공백 값은 'N' 으로 정규화
 - 블로그 리뷰: 빈 본문·2문장 미만·광고 문구 패턴 매칭 제거
 - 인텐트 데이터: 동일 text 에 상이한 label 이 존재하면 다수결 + PM 재검수로 단일화

2.2 데이터 품질 검증 결과

최종 적재된 데이터셋에 대해 4개 축(완전성·유일성·타당성·균형성)으로 품질 지표를 측정하였다. 모든 지표는 내부 품질 기준선(>= 95%)을 충족한다.

지표	정의	장소 데이터	인텐트 데이터
완전성 (Completeness)	필수 필드 NULL 없음 비율	100% (필수 5개)	100% (text-label)
유일성 (Uniqueness)	중복 레코드 제거 후 비율	100% (content_id UNIQUE)	99.6% (2건 중복 제거 후)
타당성 (Validity)	좌표·ENUM 범위 준수 비율	100% (좌표·ENUM 제약)	N/A
균형성 (Balance)	최빈·최소 클래스 비율	N/A (비분류형)	장소추천 29% / 다이어리 25% / 시설 정보 24% / 기타 22%
적정성 (Sampling)	서울 스코프 커버리지	서울 11,831 / 전국 21,192 (55.8%)	N/A

인텐트 데이터의 클래스 불균형은 최빈·최소 비율 차이 7%p 수준으로, 극심한 불균형(일반적으로 10%p 초과)에 해당하지 않는다. 다만 샘플 절대 수(490건)가 제한적이므로 5장에서 언급하는 Back-translation·동의어 치환 기반 증강을 Phase 2 확장 과제로 정의한다.

3. 데이터 전처리 절차

장소 데이터는 대량·다필드 정제 중심(70,651 → 21,192)의 5단계 클렌징 파이프라인을, 인텐트 데이터는 경량 문장 정제·라벨 일관화를 거친다. 이하 3.1~3.3은 이상치·결측·변환 절차를, 3.4는 장소 데이터의 전체 흐름을, 3.5는 벡터DB 임베딩 파이프라인을 기술한다.

3.1 이상치 탐지 및 처리

[장소 데이터]

- **이상치 기준:** 한반도 좌표 박스(위도 33.0~38.8, 경도 124.5~131.9) 이탈 / 지역 코드-행정 주소 불일치 / content_id 포맷 위배

- **처리 방법:** 좌표 범위 필터링 Pandas query 로 일괄 제거. 행정 주소는 시·도 레벨만 매칭 검증
- **품질 기여:** 좌표 기반 거리 검색 정확도 확보. MySQL ST_Distance_Sphere 호출 시 예외 방지

[인텐트 데이터]

- **이상치 기준:** 단어 수 2개 이하 발화, 비속어·광고성 문구, 동일 발화에 상이한 라벨
- **처리 방법:** 규칙 기반 필터링 + PM 교차 검수로 라벨 불일치 해소. 총 11건 제거 후 490건 확정

3.2 결측치 처리

- **결측 필드:** 장소 - operation_info, pet_restrictions, pet_size_limit, firstimage2 일부 결측. description 은 초기에 전량 결측
- **처리 방법:**
 - 필수 필드(name·address·lat·lng): 해당 행 삭제 (70,651 → 38,417 단계에서 적용)
 - 선택 필드(operation_info·pet_restrictions·pet_size_limit): NULL 유지 후 서비스 표시 단계에서 '정보 없음' 대체
 - 이미지 필드(firstimage2): NULL 허용, UI 레벨 대표 이미지 Fallback 처리
 - description: 3.3절 템플릿 기반 자동 생성으로 100% 충족
- **적용 비율:** 필수 필드 결측 제거로 약 45.6% 감축 (70,651 → 38,417). 이후 중복·이상치 단계에서 추가 감축

3.3 데이터 변환 및 재현 가능성

필드 표준화와 description 자동 생성이 핵심 변환 작업이다. 원본의 혼합된 Boolean 표기 (True/False/Y/N/1/0)를 ENUM 으로 통일하고, description 은 수록된 메타정보를 자연어 템플릿으로 결합하여 RAG 검색·LLM 요약에 사용 가능한 문장으로 가공한다.

- **Boolean 정규화:** map({True/'Y'/'1': 'Y', False/'N'/'0'/'NaN': 'N'}) → ENUM('Y','N') 로 저장
- **주소·좌표 정리:** address 공백·특수문자 정규화, lat/lng 소수점 7자리 round

- **description 생성:** name, sub_category, city/district, pet_zone_type, pet_size_limit, has_parking 을 결합한 템플릿 기반 자연어 요약

description 생성 예시 코드 (일부 발췌).

```
# ai/rag/preprocess/build_description.py (발췌)
from typing import Optional

def build_place_description(row: dict) -> str:
    """장소 레코드의 주요 필드를 자연어 요약 문장으로 결합한다.

    Args:
        row: dog_places 단일 레코드 딕셔너리.

    Returns:
        RAG 검색·LLM 요약에 활용 가능한 한국어 설명 문장.
    """
    name: str = row["name"]
    category: str = row.get("sub_category") or "반려견 동반 장소"
    region: str = f"{row.get('city', '')} {row.get('district', '')}".strip()
    size_limit: Optional[str] = row.get("pet_size_limit")
    parking: str = "가능" if row.get("has_parking") == "Y" else "불가"

    parts: list[str] = [
        f"{name}은(는) {region} 소재 {category}이다.",
        f"반려견 동반 구역은 {row.get('pet_zone_type', '정보 없음')}이며,",
        f"크기 제한은 {size_limit or '별도 제한 없음'}이다.",
        f"주차는 {parking}하다.",
    ]
    return " ".join(parts)
```

- **인텐트 텍스트 정제:** 유니코드 NFKC 정규화, 연속 공백 축약, 이모지·제어문자 제거. 소문자 강제 변환은 한국어 특성상 적용하지 않음
- **GitHub 경로:** ai/rag/preprocess/ (장소) / ai/intent/preprocess/ (인텐트)

3.4 전처리 절차 요약 (프로세스 플로우)

장소 데이터는 원천 수집 70,651건에서 5단계 클렌징을 거쳐 21,192건의 유효 레코드로 정제된다. 각 단계의 처리 기준·잔존 건수·감축률은 다음과 같다.

Step	단계	처리 기준	잔존 건수	감축률
0	원천 수집	TourAPI pet_tour 전량 수집	70,651	—

Step	단계	처리 기준	잔존 건수	감축률
1	중복 제거	content_id UNIQUE + (name,address) 유사도	52,834	- 25.2%
2	결측 필드 제거	name-address-lat-lng 중 하나라도 NULL 인 행	38,417	- 27.3%
3	좌표 필터링	한반도 좌표 박스 이탈·지역 코드 불일치	28,593	- 25.6%
4	필드 표준화	Boolean → ENUM, 주소·좌표 정규화, 타입 오류 제거	22,144	- 22.6%
5	description 생성	template 결합 후 최종 유효 레코드 확정	21,192	-4.3%

인텐트 데이터는 별도 파이프라인으로 수기 라벨링 501건 → 중복·불일치 11건 제거 → 490건으로 확정되며, 장소 파이프라인과는 독립적으로 운영된다.

3.5 임베딩 파이프라인

서울 MVP 범위 장소에 대해 블로그 리뷰를 벡터화하여 ChromaDB 에 적재한다. 한국어 문장 의미 유사도 기반 검색이 목적이므로 한국어 Dense Embedding 모델을 선정하였다.

항목	내용
임베딩 모델	jhgan/ko-sroberta-multitask
출력 차원	768 (dense vector)
선정 근거	한국어 다중 태스크(유사도·NLI·STS) 학습으로 도메인 일반화 우수. sentence-transformers 호환, CPU 추론 시 평균 120ms/문장
거리 함수	Cosine Similarity (ChromaDB HNSW index)
배치 크기	BATCH_SIZE = 50 (GPU 메모리·API 안정성 고려)
대상 범위	서울 11,831개 장소에 연결된 블로그 리뷰 텍스트 (장소당 평균 3~5건)
저장 메타	place_id, source_url, title, snippet_idx 를 ChromaDB metadata 로 부착
재현성	seed·모델 버전·device 를 이벤트 로그로 기록, 재실행 시 동일 벡터 재생성 검증

ChromaDB 적재 코드 예시 (핵심 경로만 발췌).

```

# ai/rag/indexing/embed_reviews.py (발췌)
from pathlib import Path
from typing import Iterable

import chromadb
from sentence_transformers import SentenceTransformer

EMBED_MODEL_NAME = "jhgan/ko-sroberta-multitask"
COLLECTION_NAME = "dog_places"
BATCH_SIZE = 50

def build_collection(persist_dir: Path) -> chromadb.Collection:
    """ChromaDB persistent client 를 열고 dog_places 컬렉션을 반환한다.

    Args:
        persist_dir: ChromaDB 데이터 저장 디렉터리.

    Returns:
        cosine 거리 설정이 적용된 dog_places 컬렉션 핸들.
    """
    client = chromadb.PersistentClient(path=str(persist_dir))
    return client.get_or_create_collection(
        name=COLLECTION_NAME,
        metadata={"hnsw:space": "cosine"},
    )

def embed_and_upsert(
    collection: chromadb.Collection,
    reviews: Iterable[dict],
) -> int:
    """리뷰 이터러블을 배치 단위로 임베딩하여 컬렉션에 upsert 한다.

    Args:
        collection: 대상 ChromaDB 컬렉션.
        reviews: id, document, metadata 키를 갖는 리뷰 딕셔너리 이터러블.

    Returns:
        업서트된 총 레코드 수.
    """
    model = SentenceTransformer(EMBED_MODEL_NAME)
    total: int = 0
    batch: list[dict] = []
    for review in reviews:
        batch.append(review)
        if len(batch) >= BATCH_SIZE:
            _upsert_batch(collection, model, batch)
            total += len(batch)
            batch.clear()
    if batch:
        _upsert_batch(collection, model, batch)
        total += len(batch)

```

```

return total

def _upsert_batch(
    collection: chromadb.Collection,
    model: SentenceTransformer,
    batch: list[dict],
) -> None:
    texts: list[str] = [item["document"] for item in batch]
    vectors = model.encode(texts, normalize_embeddings=True).tolist()
    collection.upsert(
        ids=[item["id"] for item in batch],
        documents=texts,
        embeddings=vectors,
        metadatas=[item["metadata"] for item in batch],
    )

```

4. 데이터셋 분리

본 프로젝트는 학습이 필요한 인텐트 데이터와 벡터 인덱싱만 수행하는 장소 데이터를 분리 전략 상 다르게 다룬다. 인텐트는 80/20 Stratified Split 을, 장소 벡터DB는 전량 인덱싱(분리 없음)을 적용한다.

4.1 인텐트 학습 데이터 분할

학습 데이터 규모(490건)가 소량이므로 Train/Validation 2-way 분할을 채택하였고, 클래스 비율을 유지하기 위해 Stratified Split 을 적용하였다. 별도 Test 세트는 Phase 2 에서 홀드아웃 테스트셋을 신규 수집하여 추가 구성한다.

구분	건수	비율	비고
Train	392	80%	모델 파라미터 학습용
Validation	98	20%	Best 체크포인트 선정·조기 종료 기준
Test (Phase 2 예정)	—	—	신규 홀드아웃 데이터 확보 후 별도 평가

- **분리 기준:** `sklearn.train_test_split(stratify=labels, random_state=42, test_size=0.2)`

- **선정 근거:**

- Stratified — 클래스 불균형 경미하나 표본 수가 작아 무작위 분할 시 특정 클래스 Val 편중 위험 (예: 기타 클래스가 Val 에 과대표집되는 시나리오)

- 80/20 — 학습 신호 확보(392건)와 검증 신뢰도(98건, 클래스별 평균 24~29건) 간 균형
- random_state=42 — 동료 팀원과 실험 공유 시 재현성 확보

4.2 장소 벡터DB 인덱싱 전략

장소 데이터는 모델 학습에 사용되지 않고 RAG 검색 소스로만 활용되므로 Train/Val/Test 분리가 적용되지 않는다. 서울 MVP 범위 11,831개 장소에 연결된 블로그 리뷰 전량을 ChromaDB 에 인덱싱하며, 품질 평가는 샘플 쿼리에 대한 Top-K Precision 정성 평가로 대체한다.

- **대상:** 서울 11,831개 장소 전량 (장소당 리뷰 3~5건, 총 약 47,000 벡터 규모 예상)
- **검증:** 샘플 쿼리 20개에 대해 Top-5 Precision 을 팀 내부 검수로 측정 (Phase 1 목표 0.8 이상)
- **증강 전략 (향후):**
 - 장소 데이터 — description 컬럼 조합(카테고리·편의시설·지역) 다각화로 동일 장소 multi-view 인덱싱
 - 인텐트 데이터 — Back-translation(ko→en→ko) + 동의어 치환으로 490건 → 1,500~2,000건 목표 확장

5. 부록

5.1 수집 데이터 샘플

장소 레코드 샘플 (dog_places 테이블) 1건 — JSON 표현.

```
{
  "content_id": "TOUR_2610123",
  "name": "도그마루 카페",
  "sub_category": "반려견 동반 카페",
  "city": "서울특별시",
  "district": "마포구",
  "address": "서울특별시 마포구 동교로 123",
  "lat": 37.5547123,
  "lng": 126.9236541,
  "is_indoor": "Y",
  "is_outdoor": "Y",
  "pet_zone_type": "전 구역 동반",
}
```

```

"pet_size_limit": "중형견(15kg) 이하",
"pet_restrictions": "목줄 착용 필수, 배변봉투 지참",
"has_parking": "Y",
"operation_info": "매일 11:00~22:00 (월요일 휴무)",
"description": "도그마루 카페(는) 서울특별시 마포구 소재 반려견 동반 카페이다. 반려견 동반 구역은 전 구역 동반이며, 크기 제한은 중형견(15kg) 이하이다. 주차는 가능하다.",
"firstimage": "https://tong.visitkorea.or.kr/cms/...",
"firstimage2": "https://tong.visitkorea.or.kr/cms/..."
}

```

인텐트 학습 샘플 3건 (text, label).

text	label
강남역 근처에 강아지랑 같이 갈 수 있는 카페 추천해줘	장소추천
오늘 우리 뽀빠랑 성수동 산책한 거 일기로 남겨줘	다이어리 작성
이 공원 주차장 있어? 운영시간도 알려줘	시설정보

블로그 리뷰 임베딩 메타 샘플.

```

{
  "id": "review_TOUR_2610123_03",
  "document": "홍대입구역에서 도보 5분. 2층 전체가 반려견 전용 공간이라 편하게 놀 수 있었어요. 중형견까지 입장 가능하고 주차는 건물 지하에...",
  "metadata": {
    "place_id": "TOUR_2610123",
    "source_url": "https://blog.naver.com/...",
    "title": "마포 강아지 카페 추천 - 도그마루",
    "snippet_idx": 3
  }
}

```

5.2 전처리 전/후 비교

항목	전처리 전 (원천)	전처리 후 (최종)
Boolean 필드	True / 'Y' / 1 / 'y' / NaN 혼용	ENUM('Y','N') 통일
좌표	37.55471234567 / 126 등 자릿수 불일치	소수점 7자리 round (37.5547123)
description	전량 NULL	템플릿 기반 자연어 요약 100% 충족
pet_restrictions	한 셀 안에 줄바꿈·특수문자 포함	' , ' 구분자로 정규화
인텐트 text	' 강남역 카페~~ 추천ㅋㅋ '	'강남역 카페 추천' (NFKC + 공백 축약 + 이모지 제거)

5.3 한계 및 개선 방향

[현재 한계]

- **인텐트 샘플 수 제약:** 490건은 4-class 분류 기준으로 경계 케이스(장소추천↔시설정보) 학습에 부족하며, 실사용 로그 수집 전까지 강건성 검증 제한
- **벡터DB 서울 한정:** 블로그 리뷰는 서울 11,831개에만 적용. 지방 장소는 RDB 메타 기반 검색으로만 대응
- **description 템플릿 획일성:** 자연어 다양성이 낮아 임베딩 검색 시 쿼리-문서 표현 간 어휘 변형 부족
- **리뷰 신선도:** 블로그 크롤링 시점 고정. 운영 정보·휴업 상태 반영 지연 위험

[개선 방향]

- **Phase 2 — 데이터 증강:** Back-translation·동의어 치환으로 인텐트 1,500~2,000건 확장. 경계 샘플 집중 보강
- **Phase 3 — 전국 확장:** 지역별 크롤링 파이프라인 병렬화로 비서울 지역 리뷰 커버리지 확보
- **description 다양화:** LLM 기반 2~3가지 톤 변형 생성으로 동일 장소 multi-view 임베딩 (검색 리콜 향상)
- **주기적 재임베딩:** 월 1회 배치 재크롤링·재임베딩 Cron 을 AWS EventBridge 로 스케줄링
- **품질 모니터링:** 실사용자 쿼리-Top5 정답률 지표를 프로덕션에서 집계하여 임베딩 모델 교체 판단 근거로 활용

5.4 참조 문헌 및 코드 링크

- **한국관광공사 TourAPI 4.0 pet_tour:** <https://api.visitkorea.or.kr/#/>
- **공공데이터포털:** <https://www.data.go.kr>
- **jhgan/ko-sroberta-multitask:** <https://huggingface.co/jhgan/ko-sroberta-multitask>
- **ChromaDB 공식 문서:** <https://docs.trychroma.com>
- **sentence-transformers:** <https://www.sbert.net>
- **전처리 코드 (장소):** ai/rag/preprocess/ (GitHub 게시 예정)

- 임베딩 코드: ai/rag/indexing/embed_reviews.py
- 인텐트 전처리 코드: ai/intent/preprocess/ (GitHub 게시 예정)
- 관련 산출물: 『데이터 전처리 인공지능 학습 결과서 v2』, 『학습된 인공지능 모델 명세서』